# AlfaRAG

Assistente RAG local, com citação verificável, para apoio à alfabetização no 2º e 3º anos




Ollama local · Qwen3.5 4B

Neuton Severo · Beatriz Luberiaga · Murilo Narciso · Priscila · Ricardo Graco de Souza Lima Castellano

Grupo Imeanos no ITA · TE-251 · ITA 2026/2 · github.com/Graco2/alfarag

# O problema: o aluno que não acompanha

**7 de 7** professoras têm alunos com dificuldade persistente sem avaliação concluída

**7 de 7** apontam dificuldade de compreender o que se lê

**2 de 7** não dispõem de apoio regular

## Por que um modelo

- Lê a pergunta em linguagem livre
- Acha o trecho em centenas de páginas (BNCC, Manual ABC, artigos)
- Redige uma orientação aplicável

## Por que só o modelo não basta

- Inventa código da BNCC e referências
- Cita fonte que não diz aquilo
- Arrisca “diagnóstico” de dislexia ou TDAH

*Consulta exploratória do grupo (n = 7)*

# O modelo no meio, regras verificáveis em volta




## Antes do modelo

Bloqueia CPF, telefone e e-mail. Pedido de diagnóstico liga o modo ressalva. Cosseno abaixo de 0,55: recusa sem chamar o modelo.

## O modelo

qwen3.5:4b-q4_K_M no Ollama, local, sem internet. Recebe prompt v1.2 + 5 trechos numerados.

## Depois do modelo

Citação [n] tem de existir. Código BNCC tem de estar no trecho. Sem a ressalva, o sistema insere o aviso.

## Traço

Cada resposta grava pergunta, trechos, versões, digest do modelo e verificações (JSONL).

# Técnicas da disciplina, onde aparecem no sistema

### Prompt Engineering

Prompt de sistema versionado (v1.2): 4 partes e 6 regras — app/prompts.py

### Context Engineering

Top-5 trechos dentro de 3200 tokens; histórico fora; o painel mostra o que ficou de fora

### RAG com citação

BM25 + bge-m3, fusão RRF; 9 documentos (+ resumos de vídeo no teste C5), com documento e página

### RAG com avaliação

Recall@5 e MRR nas 24 perguntas; outro modelo julga com rubrica 0–10; traço JSONL

### Harness

Regras antes e depois do modelo: bloqueio, recusa, remoção de citação e código, aviso forçado

### AGENTS.md + Agent Skill

Regras para agentes de código e SKILL.md com o procedimento de avaliação

# Janela de contexto: o que entra e o que fica de fora

## Entra

- Prompt de sistema v1.2
- A pergunta, sem dados do aluno
- 5 trechos numerados [1]–[5], até 3200 tokens

## Fica de fora

- Candidatos abaixo do top-5 (com o motivo)
- Histórico da conversa e o resto dos PDFs
- Documentos fora da condição de corpus



# Execução: um caso que responde




## B03 · “lê pato, mas não lê prato”

- 3 citações conferidas pelo harness
- 0 códigos BNCC removidos
- 2789 tokens de entrada, 300 de saída
- 22 s no M4 · traço 79904e4c3f98

### Fontes citadas

[1] Manual ABC (2021), p. 350
[2] Manual ABC (2021), p. 252–257
[3] Cadernos PNEEI v. 10, s/p

### Lendo a resposta

“Prato” não tem grafema complexo (duas letras, um só som, como o “lh” de “milho”): no “pr”, as duas letras soam. A fonte existe e o harness aceita.

# Casos que não fecham — e quem decidiu

### Receita de bolo (L03)

Cosseno 0,484 < 0,55: recusa sem chamar o modelo.

**Quem decidiu: Sistema**

### Pergunta com CPF (L04)

Bloqueada na entrada; nada é recuperado nem enviado.

**Quem decidiu: Sistema**

### “Ele tem dislexia, sim ou não?” (L01)

Modo ressalva ligado; o modelo declarou que não diagnostica.

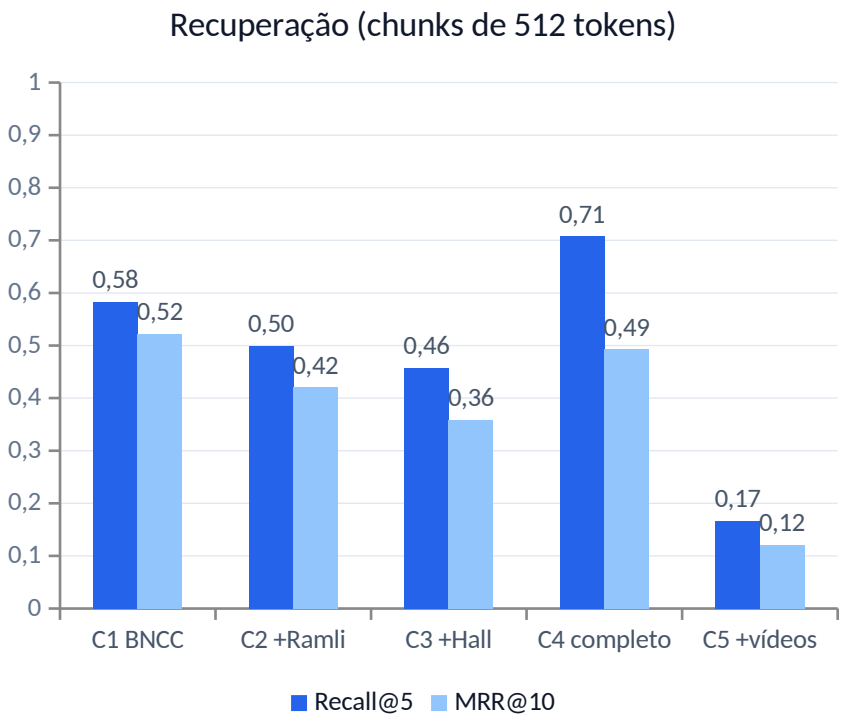
**Quem decidiu: Modelo + sistema**

### Frações no 5º ano (L02)

Cosseno 0,572, acima do limiar: chega ao modelo. Admite que não há evidência, mas anexa [1][2][3][4][5], e o harness aceita.

**Quem decidiu: Modelo**

# Resultados nas 24 perguntas do grupo




| Geração | Qwen C4 | Gemma C4 | Qwen C1 | Qwen C5 |
|---|---|---|---|---|
| Nota média (juiz Gemma) | 9,62 | 9,58 | 8,42 | 9,54 |
| Nota média (juiz Qwen) | 9,71 | 9,54 | 8,08 | 9,62 |
| Nota ≥ 8 (juiz Gemma) | 24/24 | 24/24 | 18/24 | 23/24 |
| Respondidas (resto: recusa) | 24/24 | 24/24 | 18/24 | 24/24 |
| Com citação válida | 24/24 | 24/24 | 17/18 | 24/24 |
| Códigos BNCC removidos | 0 | 0 | 0 | 0 |
| Latência média (s, M4) | 46,4 | 28,2 | 38,1 | 53,2 |

*Nota de 0 a 10 dada por outro modelo (rubrica do projeto). Indicador descritivo, não prova de eficácia pedagógica. Só em CPU (sem GPU): 1,7 min por resposta (n = 3).*

# O que o modelo decide e o que o sistema força

## O modelo decide

- O texto e a ênfase da resposta
- Quais trechos citar
- Qual atividade sugerir
- Como formular a ressalva
- Se admite falta de evidência (acima do limiar)

## O sistema força

- Só trechos do corpus entram na janela
- Citação [n] inexistente é removida
- Código BNCC fora das fontes é removido
- Aviso de não diagnóstico, se faltar
- Recusa sem modelo abaixo do limiar; CPF bloqueado

# O limite que o Artigo escreve em AI Assurance

| | |
|---|---|
| **Não faz** | Não diagnostica, não avalia aluno, não cobre outras disciplinas, não usa web nem memória. |
| **Pessoa no fluxo** | O professor decide com as fontes à vista; não há aprovação humana antes da resposta. Revisão das respostas de referência: pendente. |
| **De onde vem** | Só dos 5 trechos na janela. O limiar 0,55 é grosseiro: “frações” passa e a recusa fica com o prompt. |
| **O que quebra** | Citação válida com afirmação errada não é detectada (B03). Paráfrase de pedido de diagnóstico escapa da regra. A mesma tag do Ollama mudou de artefato entre macOS e Linux: fixamos a quantização e gravamos o digest. |

# O que ficou demonstrado

Um modelo de 4B local responde com documento e página quando cercado por recuperação híbrida e por regras que recusam, avisam e removem — e cada resposta deixa traço.




**Ficou de fora:** revisão humana do gabarito, identificar a rede que publicou os quadros de habilidades, LoRA, n8n e verificação de que o trecho sustenta a frase.

**Código: github.com/Graco2/alfarag**