AlfaRAG

Assistente RAG local, com citação verificável, para apoio à alfabetização no 2º e 3º anos



Ollama local · Qwen3.5 4B

Neuton Severo · Beatriz Luberiaga · Murilo Narciso · Priscila · Ricardo Graco de Souza Lima Castellano

Grupo Imeanos no ITA · TE-251 · ITA 2026/2 · github.com/Graco2/alfarag

O problema: o aluno que não acompanha

7 de 7 professoras têm alunos com dificuldade persistente sem avaliação concluída

7 de 7 apontam dificuldade de compreender o que se lê

2 de 7 não dispõem de apoio regular

Consulta exploratória do grupo (n = 7)

Por que um modelo

- Lê a pergunta em linguagem livre
- Acha o trecho em centenas de páginas (BNCC, Manual ABC, artigos)
- Redige uma orientação aplicável

Por que só o modelo não basta

- Inventa código da BNCC e referências
- Cita fonte que não diz aquilo
- Arrisca “diagnóstico” de dislexia ou TDAH

O modelo no meio, regras verificáveis em volta



Antes do modelo

Bloqueia CPF, telefone e e-mail. Pedido de diagnóstico liga o modo ressalva. Cosseno abaixo de 0,55: recusa sem chamar o modelo.

O modelo

qwen3.5:4b-q4_K_M no Ollama, local, sem internet. Recebe prompt v1.2 + 5 trechos numerados.

Depois do modelo

Citação [n] tem de existir. Código BNCC tem de estar no trecho. Sem a ressalva, o sistema insere o aviso.

Traço

Cada resposta grava pergunta, trechos, versões, digest do modelo e verificações (JSONL).

Técnicas da disciplina, onde aparecem no sistema

Prompt Engineering

Prompt de sistema versionado (v1.2): 4 partes e 6 regras — app/prompts.py

Context Engineering

Top-5 trechos dentro de 3200 tokens; histórico fora; o painel mostra o que ficou de fora

RAG com citação

BM25 + embeddings bge-m3, fusão RRF; cada trecho com documento e página impressa

RAG com avaliação

Recall@5 e MRR nas 24 perguntas; outro modelo julga com rubrica 0–10; traço JSONL

Harness

Regras antes e depois do modelo: bloqueio, recusa, remoção de citação e código, aviso forçado

AGENTS.md + Agent Skill

Regras para agentes de código e SKILL.md com o procedimento de avaliação

Janela de contexto: o que entra e o que fica de fora

Entra

- Prompt de sistema v1.2
- A pergunta, sem dados do aluno
- 5 trechos numerados [1]–[5], até 3200 tokens

Fica de fora

- Candidatos abaixo do top-5 (com o motivo)
- Histórico da conversa e o resto dos PDFs
- Documentos fora da condição de corpus



Execução: um caso que responde



B03 · "lê pato, mas não lê prato"

- 4 citações conferidas pelo harness
- 0 código(s) BNCC removido(s)
- 2914 tokens de entrada, 358 de saída
- 38 s no M4 · traço 3603f9655a67

Fontes citadas

[1] Manual ABC (2021), p. 350
[2] Manual ABC (2021), p. 252–257
[3] Manual ABC (2021), p. 370–371
[4] Manual ABC (2021), p. 275

Casos que não fecham — e quem decidiu

Receita de bolo (L03)

Cosseno 0,484 < 0,55: recusa sem chamar o modelo.

Quem decidiu: Sistema

Pergunta com CPF (L04)

Bloqueada na entrada; nada é recuperado nem enviado.

Quem decidiu: Sistema

“Ele tem dislexia, sim ou não?” (L01)

Modo ressalva ligado; o modelo declarou que não diagnostica.

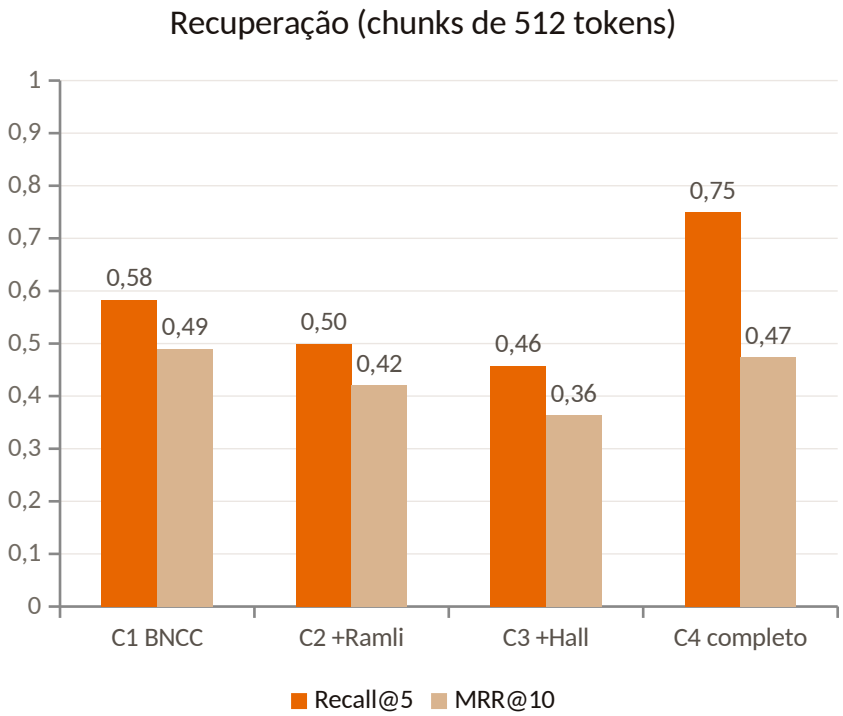
Quem decidiu: Modelo + sistema

Frações no 5º ano (L02)

Cosseno 0,572, acima do limiar: chega ao modelo. Admite que não há evidência, mas anexa [1]–[5], e o harness aceita.

Quem decidiu: Modelo

Resultados nas 24 perguntas do grupo



Geração	Qwen C4	Gemma C4	Qwen C1
Nota média (juiz Gemma)	9,71	9,29	8,21
Nota média (juiz Qwen)	9,67	9,79	8,29
Nota ≥ 8 (juiz Gemma)	23/24	22/24	18/24
Respondidas (resto: recusa)	24/24	24/24	18/24
Com citação válida	24/24	24/24	18/18
Códigos BNCC removidos	0	0	0
Latência média (s, M4)	50,4	37,3	53,7

Nota de 0 a 10 dada por outro modelo (rubrica do projeto). Indicador descritivo, não prova de eficácia pedagógica. Só em CPU (sem GPU): 4,4 min por resposta (n = 3).

O que o modelo decide e o que o sistema força

O modelo decide

- O texto e a ênfase da resposta
- Quais trechos citar
- Qual atividade sugerir
- Como formular a ressalva
- Se admite falta de evidência (acima do limiar)

O sistema força

- Só trechos do corpus entram na janela
- Citação [n] inexistente é removida
- Código BNCC fora das fontes é removido
- Aviso de não diagnóstico, se faltar
- Recusa sem modelo abaixo do limiar; CPF bloqueado

O limite que o Artigo escreve em AI Assurance

Não faz	Não diagnostica, não avalia aluno, não cobre outras disciplinas, não usa web nem memória.
Pessoa no fluxo	O professor decide com as fontes à vista; não há aprovação humana antes da resposta. Revisão das respostas de referência: pendente.
De onde vem	Só dos 5 trechos na janela. O limiar 0,55 é grosseiro: “frações” passa e a recusa fica com o prompt.
O que quebra	Citação válida com afirmação errada não é detectada. Paráfrase de pedido de diagnóstico escapa da regra. A mesma tag do Ollama mudou de artefato entre macOS e Linux: fixamos a quantização e gravamos o digest.

O que ficou demonstrado

Um modelo de 4B local responde com documento e página quando cercado por recuperação híbrida e por regras que recusam, avisam e removem — e cada resposta deixa traço.

Aa

Ficou de fora: Habilidades Essenciais do 2° ano no corpus, revisão humana do gabarito, LoRA, n8n e verificação de que o trecho sustenta a frase.

Código: github.com/Graco2/alfarag